Etat de l'art des Small Language Models (SLMs) à moins de 14 milliards de paramètres

JIMENEZ Henry[a*], GOARIN Eliot[a*], MOKRANI Titouan[a*], DANG Hoang[a*], KALEMBA Noah[a*]

[a]Occitanie, Université Toulouse III, Toulouse, France

[*]JIMENEZ Henry, JIMHen, Alfonso; henry.jimenez-chacon@utoulouse.com

[*]GOARIN: Eliot, GOAEli, Eliot; goarin.eliot@utoulouse.fr

[*]MOKRANI: Titouan, MOKTi, Titouan; mokrani.titouan@utoulouse.fr

[*]DANG: Hoang, DANGh, Hoang; dang.hoag@utoulouse.fr

[*]KALEMBA: Noah, KALEMB, Noah; kalemba.noah@utoulouse.fr

Abstract

Si les LLMs ont redéfini les capacités de l'IA générative, leur adoption reste freinée par des exigences matérielles hors de portée pour la majorité des développeurs et organisations. Ce travail interroge la viabilité des Small Language Models (SLMs) comme alternative accessible, en soumettant six modèles de moins de 14 milliards de paramètres à une batterie d'évaluations couvrant sept dimensions cognitives et fonctionnelles clés. Il ressort de cette analyse qu'un SLM bien entraîné peut rivaliser avec des modèles bien plus lourds : Phi-4 14B se distingue par sa régularité toutes tâches confondues, tandis que Qwen 3.5 9B démontre qu'une architecture hybride soigneusement optimisée surpasse des modèles sensiblement plus grands sur les tâches analytiques les plus exigeantes.

Keywords: Informatique; Intelligence Artificielle; SLM, Performance, Benchmarks

Author roles: Titouan Mokrani : Data curation, Visualisation, Review, Editing and Writing
Eliot Goarin Project administration, Validation and Writing
Alfonso JIMENEZ Investigation, Writing and Supervision
DANG Hoang Conceptualization, Writing and Methodology
KALEMBA Noah Formal Analysis and Writing

1 Introduction

L'essor des grands modèles de langage (Large Language Models, LLMs) tels que GPT-4, Claude ou Gemini a marqué un tournant décisif dans le traitement automatique du langage naturel. Cependant, leur déploiement reste conditionné à des infrastructures de calcul coûteuses, typiquement des clusters de GPU haute performance comme les NVIDIA A100 ou H100, ce qui en limite considérablement l'accessibilité pour les développeurs indépendants, les chercheurs et les entreprises de taille modeste.

C'est dans ce contexte qu'émerge un intérêt croissant pour les Small Language Models (SLMs), définis comme des modèles de langage dont le nombre de paramètres est inférieur à 14 milliards. Cette définition ne fait pas l'objet d'un consensus établi dans la littérature, le seuil variant selon les travaux et les usages ; nous précisons nos critères de délimitation en section 2. Des travaux récents autour des familles Phi (Microsoft), Orca (Microsoft), Qwen (Alibaba), OLMo ou LLaMA (Meta) ont mis en évidence un constat contre-intuitif : la réduction du nombre de paramètres, lorsqu'elle est accompagnée de stratégies d'entraînement rigoureuses (données de haute qualité, distillation, auto-évolution), ne se traduit pas nécessairement par une dégradation proportionnelle des performances.

Cette dynamique soulève la question centrale de ce travail : **Quels sont les Small Language Models les plus performants sur chacune des grandes catégories de benchmarks établis, tout en restant exécutables sur un GPU grand public ?** Dans ce travail, nous retenons comme critère opérationnel qu'un modèle de moins de 14 milliards de paramètres est, en pratique, exécutable sur un GPU grand public (tel que les séries NVIDIA RTX 3000/4000, dont la VRAM est typiquement comprise entre 8 et 24 Go). Ce seuil constitue ainsi notre définition implicite d'un SLM compatible matériel grand public, indépendamment du fait que les articles étudiés mentionnent ou non explicitement ce type de hardware.

Pour y répondre, cet état de l'art s'articule autour de cinq axes : les critères de sélection des articles scientifiques retenus, l'explication du choix des critères d'exécution sur GPU grand public, une illustration et justification du choix des six grandes catégories de benchmarks (raisonnement, compréhension du langage, génération de code, connaissances factuelles, mathématiques, sécurité et alignement), une analyse des SLMs les plus compétitifs au sein de chacune d'elles et enfin les limites de notre étude. Ce travail contribue ainsi à une démocratisation raisonnée de l'IA générative, en dissociant performance et exigences matérielles jusqu'ici jugées incontournables.

2 Méthodologies pour le filtrage et évaluation d'articles

Notre sélection d'articles repose sur une approche itérative, structurée en plusieurs cycles de filtrage progressivement plus stricts. Cette démarche, allant d'une lecture générale vers une analyse spécialisée, nous a permis de réévaluer le corpus à plusieurs reprises jusqu'à converger vers un ensemble final de 20 articles annotés. La recherche a été conduite sur des articles publiés entre 2024 et 2026, en s'appuyant principalement sur les bases de données.

2.1 Critères d'exclusion

Un premier filtrage massif a été effectué sur la base des abstracts. Ont été exclus tous les articles ne présentant pas d'étude comparative des performances de SLMs — c'est-à-dire tout travail n'introduisant ni benchmark dédié aux SLMs, ni évaluation comparative d'un modèle face à des références existantes ainsi que les doublons. À l'issue de cette étape, 150 articles sur 200 ont été écartés, constituant une base de 50 articles pour la suite du processus.

2.2 Critères de sélection

Le filtrage s'est ensuite déroulé en trois opérations successives : Filtre sur abstract et introduction — Un second filtre, plus strict, a été appliqué en élargissant la lecture aux introductions des articles. Cette étape a permis d'évaluer l'architecture proposée, les résultats de l'étude et la pertinence de chaque contribution par rapport à notre sujet. Elle visait à réduire le corpus initial à une cinquantaine d'articles.
Première lecture complète — Les 50 articles retenus ont fait l'objet d'une première lecture intégrale par l'équipe de recherche, permettant d'évaluer leur profondeur et leur adéquation avec notre problématique.
Sélection finale — À l'issue de cette lecture, 15 articles ont été identifiés comme suffisamment pertinents et rigoureux pour passer l'étape d'annotation détaillée.

2.3 Critères d'annotation

Les 15 articles retenus ont été évalués selon les six aspects suivants :

Utilité - Identification de l'apport unique de l'article au sein du corpus, et du domaine dans lequel il pourra étayer notre argumentation.

Limites - Identification des faiblesses de l'article, qu'il s'agisse d'un manque d'alignement avec notre sujet ou de biais méthodologiques, notamment lors de l'entraînement des modèles présentés.

Public cible - Évaluation de l'adéquation entre le public visé par l'article et celui de notre état de l'art, afin d'adapter le registre de citation.

Méthodes - Pour les articles présentant un modèle ou une famille de modèles, spécification des méthodes d'entraînement retenues, l'ensemble de données utilisées et l'architecture de base du model. Pour les états de l'art, description des méthodes d'analyse et de sélection d'articles.

Fiabilité - Vérification de la revue ou de la conférence de publication via [ex. Semantic Scholar, Google Scholar], contrôle de la validité des citations internes, et examen de la pertinence de l'usage des benchmarks au regard des recommandations de leurs auteurs.

Profil des auteurs - Les auteurs ne sont pas évalués sur leur réputation personnelle, mais sur le retour de la communauté scientifique : nombre total de citations reçues, réactivité dans leur domaine de recherche et volume de publications.

Conclusion - La/les conclusions de l'article sont évaluées dans cette partie. On devra faire preuve d'esprit critique et identifier des discrépances dans la collecte de données, résultats affichés ou sur son analyse.

2.4 Méthode Snowball

En complément de cette démarche, nous avons appliqué la méthode Snowball, qui consiste à identifier des articles susceptibles de passer nos filtres en s'appuyant sur les références bibliographiques des 15 articles sélectionnés. Cette méthode nous a permis d'ajouter 5 articles à notre corpus, elles-mêmes soumirent au processus d'annotation complet.

3 Critères d'exécution sur un GPU grand public et consommation

Pourquoi les GPU sont-ils indispensables à l'entraînement et à l'inférence des LLM/SLM ?

L'entraînement et l'inférence des modèles de langage reposent sur des opérations massivement parallèles (multiplications matricielles, mises à jour de paramètres, calculs de gradients) structurellement inadaptées aux CPU généralistes. Les GPU, grâce à leur architecture massivement parallèle, accélèrent ces calculs d'un facteur considérable par rapport à une implémentation CPU, un avantage établi dès 2009 Raina et al. (2009) et amplifié depuis par l'évolution conjointe des architectures GPU et des modèles de langage Li et al. (2025).

Définition du GPU grand public retenue

Par GPU grand public, nous entendons une carte graphique destinée au marché consumer desktop, commercialisée par les trois principaux fabricants (AMD, Intel et Nvidia) et conçue pour être installée sur un ordinateur de bureau standard, par opposition aux GPU de classe entreprise ou datacenter tels que les NVIDIA H100 ou A100. Adamski and Lubczonek (2025), dans leur analyse comparative de cartes grand public pour le deep learning, retiennent précisément cette définition opérationnelle et démontrent que ces dispositifs sont capables de prendre en charge des tâches d'apprentissage profond réelles, avec des performances, une efficacité énergétique et un coût d'entrée très variables selon le fabricant et le modèle.

Convention dans la littérature et choix du seuil à 14 milliards de paramètres

La littérature scientifique ne propose pas de seuil universel permettant de définir à partir de combien de paramètres un modèle de langage peut ou ne peut plus tourner sur GPU grand public, ce seuil dépendant du matériel disponible, du niveau de quantification appliqué et des usages visés. En l'absence de consensus, nous fixons ce seuil à 14 milliards de paramètres, en nous appuyant sur deux éléments complémentaires. D'une part, Koh et al. (2026) observent qu'un modèle de 14B paramètres s'inscrit dans les limites mémoire des GPU grand public. D'autre part, la quantification permet de réduire significativement l'empreinte mémoire d'un modèle : en abaissant la précision des poids de FP16 à INT4, des outils comme GPTQ (Frantar et al., 2023) ou GGUF via `llama.cpp` réduisent cette empreinte d'environ 75%, au prix d'une dégradation des performances généralement inférieure à 1% sur les benchmarks standards (Frantar et al., 2023). Un modèle de 14B paramètres, qui nécessite environ 28 Go en FP16, descend ainsi à approximativement 7 Go en INT4, le rendant techniquement exécutable sur des GPU grand public disposant de 8 à 24 Go de VRAM, tels que les séries NVIDIA RTX 3000/4000. Il ne s'agit pas d'une définition standard, mais d'un repère pratique et doublement justifié, cohérent avec les pratiques observées dans la littérature récente.

Quel consommation attendre d'un SLM ?
Afin d'estimer la consommation de ressources de calcul d'un SLM, il convient de distinguer les différentes phases de son cycle de vie. Si tout réseau de neurones atteint son pic de consommation lors de la phase d'entraînement, il est crucial de prendre également en compte l'empreinte énergétique liée à l'inférence. En effet, pour des modèles open-source ou largement diffusés, la consommation cumulée en inférence peut, à terme, excéder celle de l'entraînement. Bien que la transparence concernant les émissions de gaz à effet de serre (GES) reste limitée, Meta AI a publié les données relatives à Llama (Touvron et al., 2023), dont l'entraînement total a généré 82 tCO_2eq. À titre de comparaison, les auteurs évaluent les émissions du modèle OPT à 1015 tCO_2eq pour une période d'entraînement de 34 jours. Selon (Thanh Pham et al., 2025), une étude portant sur 15 SLM open-source (incluant Llama-3.2-1B et GPT-Neo-1.3B) indique une durée moyenne d'entraînement de 14 jours. Sous l'hypothèse d'une intensité carbone comparable à celle de OPT, on peut estimer à 417 tCO_2eq l'empreinte moyenne de ces 15 modèles représentatifs en 2025. Cette mesure de l'empreinte carbone permet d'évaluer indirectement la consommation énergétique et, par extension, l'utilisation des ressources GPU. Enfin, d'après (Thanh Pham et al., 2025), le modèle présentant l'efficacité énergétique la plus élevée (le moins consommateur) demeure Llama-2-7B

Distillation & Méthodes d'optimisation
La distillation est une technique de compression de modèles permettant d'entraîner un *Small Language Model* (SLM, dit « étudiant ») en utilisant les connaissances préexistantes d'un *Large Language Model* (LLM, dit « enseignant ») déjà entraîné. Cette technique permet, de manière générale, de réduire considérablement le temps d'entraînement tout en obtenant des résultats remarquables pour le modèle étudiant. Les auteurs de Qwen démontrent avec Yang et al. (2025) qu'il est possible d'optimiser davantage ce processus via la *Strong-to-Weak Distillation*. Cette technique consiste, dans une première étape, à apprendre au SLM à raisonner, pour ensuite, dans une deuxième étape, effectuer un ajustement fin (*fine-tuning*) en alignant ses *logits* sur ceux du modèle enseignant. L'efficacité de cette méthode est prouvée par la comparaison du temps d'exécution GPU face à l'apprentissage par renforcement (*Reinforcement Learning*) : la distillation n'a nécessité qu'un dixième du temps de calcul, rendant l'usage du renforcement learning moins compétitif dans ce scénario précis.

4 Les 6 catégories de benchmark

L'évaluation des Small Language Models (SLMs) nécessite des métriques précises pour déterminer si une architecture à l'empreinte mémoire réduite peut réellement concurrencer des modèles massifs. On a choisi de structurer cette évaluation autour de six catégories, chacune ciblant une dimension cognitive ou fonctionnelle spécifique pertinente pour définir la performance d'un SLM.

1. Raisonnement (Reasoning) Le raisonnement logique et de sens commun permet de distinguer un modèle capable de déduire des solutions de celui qui se contente de mémoriser des motifs. Les SLMs peuvent apprendre à appliquer diverses stratégies de résolution (réflexion étape par étape, vérification, etc.) plutôt que de simplement imiter des réponses directes, comme l'a démontré l'entraînement du modèle Orca 2. Les capacités de raisonnement sont évaluées par des benchmarks tels que BigBench-Hard (BBH) pour les tâches complexes en plusieurs étapes, ainsi que HellaSwag, PIQA, WinoGrande et ARC pour le raisonnement de bon sens et l'inférence physique.
2. Compréhension du langage (Language Understanding) : Cette catégorie constitue le socle de l'évaluation textuelle. Le benchmark MMLU (Massive Multitask Language Understanding) s'impose comme la référence standard dans la littérature pour mesurer la compréhension générale et la rétention de connaissances sur des dizaines de disciplines. MMLU agit comme un test généraliste indépendant de l'architecture ou de la méthode d'entraînement. À cela s'ajoutent des tests de compréhension de lecture stricts comme RACE ou SQuADv2.
3. Génération de code (Code Generation) : L'usage des SLMs comme assistants de programmation locaux répond à un besoin critique de confidentialité des données et du code source. Les compétences en génération de fonctions algorithmiques sont classiquement mesurées via HumanEval et MBPP. La recherche s'oriente cependant vers des évaluations plus complexes à l'échelle d'un projet entier (Repository-Centric). Des benchmarks comme SWE-bench testent la capacité du modèle à résoudre des bugs réels issus de GitHub, ce qui exige de naviguer dans une architecture logicielle étendue. Des approches d'entraînement spécialisées montrent d'ailleurs qu'un SLM de 4 milliards de paramètres peut y surpasser des modèles ouverts jusqu'à 8 fois plus volumineux.
4. Connaissances factuelles (Factual Knowledge) : La mémorisation factuelle est la faiblesse structurelle majeure des SLMs. En raison de leur taille réduite, la capacité de ces modèles à stocker des faits bruts dans leurs poids est fondamentalement limitée. Les performances sur des benchmarks ciblant les questions ouvertes comme TriviaQA, Natural Questions (NQ) ou OpenBookQA s'en ressentent. La solution privilégiée pour pallier ce déficit consiste à intégrer des systèmes de Génération Augmentée par la Recherche (RAG) ou à coupler le modèle avec un moteur de recherche externe. Le SLM délègue ainsi le stockage des faits pour se concentrer sur la synthèse du contexte récupéré.
5. Mathématique : Ce critère évalue les compétences en arithmétique et la résolution de problèmes verbaux. GSM8K est le benchmark le plus utilisé pour les problèmes de niveau primaire, tandis que MATH cible des problèmes de compétition plus ardus. Les limites paramétriques des SLMs peuvent être contournées lors de l'inférence en appliquant des méthodes de réflexion profonde. L'approche rStar-Math, utilisant une recherche arborescente (Monte Carlo Tree Search) guidée par un modèle de récompense, a par exemple permis à des modèles restreints comme Phi-3-mini ou Qwen d'atteindre des scores de pointe sur le benchmark MATH, rivalisant avec de très grands modèles.
6. Sécurité et alignement (Security and Alignment) : Le déploiement de modèles sur des appareils grand public (smartphones, ordinateurs personnels) impose des exigences strictes pour éviter la génération de contenus toxiques ou d'hallucinations. Les SLMs, en raison de leurs capacités réduites, sont particulièrement sujets aux hallucinations lorsqu'ils tentent de combler un manque de connaissances. L'alignement est évalué via des benchmarks comme ToxiGen pour la toxicité, TruthfulQA pour la véracité des faits, ou encore les critères HHH (Helpful, Honest, Harmless). Les phases d'alignement post-entraînement, telles que le DPO (Direct Preference Optimization) ou le RLHF, sont indispensables pour sécuriser les réponses générées.

Ces 6 divers catégories ont été choisi en partant de divers critères. Comme Mahade Hasan et al. (2025) l'ont effectué dans leur des SLM's. Ils ont défini 4 critères adaptés a leur analyse. Dans notre cos en peut en resortir deux: Il doit être bien établi et frequement utilisé dans la communauté. Il doit inclure diverses tâches de synthèse et de summarization. Il doit evaluer les models dans des différentes dimensions. De plus, on trouve que les dimensions les plus évaluées trouvées par Corradini et al. (2025) sont très alignées avec nos dimensions définis ci-dessus.

On décide d'ajouter la catégorie Sécurité et alignement qui correspond à un approche plus spécialisé de la catégorie "Responsible AI" que selon Corradini et al. (2025) est un domaine en émergence qui devrait être pris en compte. On a donc décidé aussi de l'ajouter en utilisant des benchmarks comme Lin et al. (2022).

5 Évaluation des SLMs

5.1 Présentation des modèles

La sélection des modèles de langage de petite taille (inférieurs à 14 milliards de paramètres) s'articule autour d'architectures optimisées pour maximiser le rapport entre la capacité de raisonnement et l'empreinte computationnelle (Corradini et al., 2025). Les modèles étudiés incluent la famille Phi-4 de Microsoft (Microsoft et al., 2025), SmolLM3 (3B) d'HuggingFace (Bakouch et al., 2025), Olmo 3 de l'Allen Institute for AI (Olmo et al., 2025), ainsi que les itérations Qwen 3 (14B) (Yang et al., 2025) et Qwen 3.5 (9B) d'Alibaba (Team, 2026). La pertinence de ce panel réside dans la diversité de leurs approches d'entraînement et d'architecture. Ces modèles intègrent des paradigmes avancés tels que l'utilisation massive de données synthétiques (Abdin et al., 2024), des architectures hybrides combinant attention et réseaux d'experts (Mixture-of-Experts), ou encore des post-entraînements ciblant spécifiquement le raisonnement logique par optimisation des préférences (APO) ou par apprentissage par renforcement (RL) (Olmo et al., 2025; Yang et al., 2025).

5.2 Protocole d'évaluation et benchmarks

L'évaluation de ces architectures repose sur six bancs d'essai standardisés permettant de quantifier les capacités cognitives des modèles selon différents axes. Le Massive Multitask Language Understanding (MMLU) évalue les connaissances générales à travers de multiples disciplines. Le MMLU-Pro (Wang et al., 2024) en est une version plus robuste, créée pour pallier l'évolution rapide des modèles en élargissant les choix de réponses à dix options et en éliminant les questions triviales, mesurant ainsi un raisonnement analytique plus profond. Les compétences logico-mathématiques sont quantifiées par le GSM8K, axé sur la résolution de problèmes mathématiques séquentiels, et par le BIG-Bench Hard (BBH) (Suzgun et al., 2022), ciblant des tâches nécessitant des heuristiques complexes. Enfin, la génération et l'exactitude fonctionnelle du code informatique sont testées via les métriques HumanEval (Chen et al., 2021) et MBPP.

Il convient de noter que les méthodologies d'évaluation varient selon les laboratoires : Phi-4 mini, SmolLM3 et Qwen3-14B exploitent des approches de type Chain-of-Thought (CoT) pour maximiser leurs scores (Guan et al., 2025; Mitra et al., 2023). Par ailleurs, la partialité potentielle des résultats doit être considérée, les évaluations émanant majoritairement des concepteurs eux-mêmes (Mahade Hasan et al., 2025).

5.3 Résultats

Modèle	**MMLU**	**GSM8K**	**MMLU-Pro**	**BBH**	**HumanEval**	**MBPP**
Phi-4 14B	**84.8**	80.6	71.5	55.24	**82.6**	**76.5**
Phi-4 mini	67.3	88.6	52.8	70.4	74.4	65.3
SmolLM3	55.7	67.63	32.70	-	29.4	52.91
Olmo 3	76.9	87.4	-	**86.7**	49.1	60.2
Qwen 3 14B	81.05	**92.49**	61.03	81.07	-	73.4
Qwen 3.5 9B	78.2	85.4	**82.5**	-	72.6	-

Table 1: Synthèse des performances des SLMs. Les valeurs en gras indiquent le meilleur résultat (SOTA) par métrique.

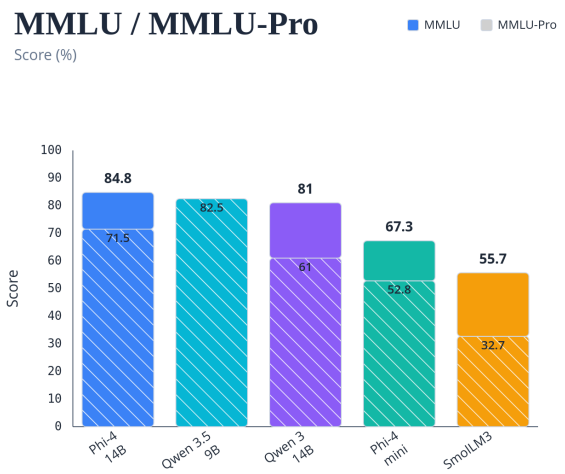

(a) Évaluation des connaissances (MMLU & MMLU-Pro)

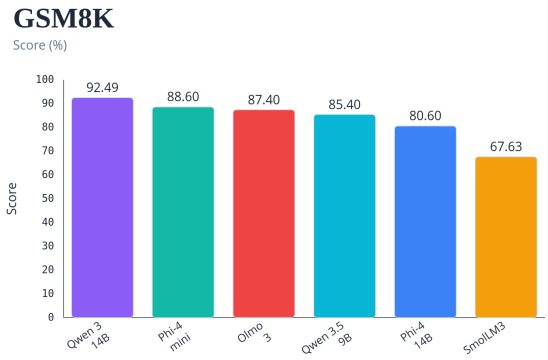

(b) Mathématiques (GSM8K)

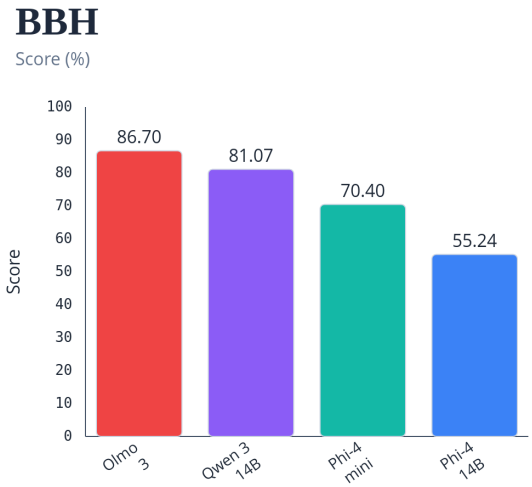

(c) Raisonnement heuristique complexe (BBH)

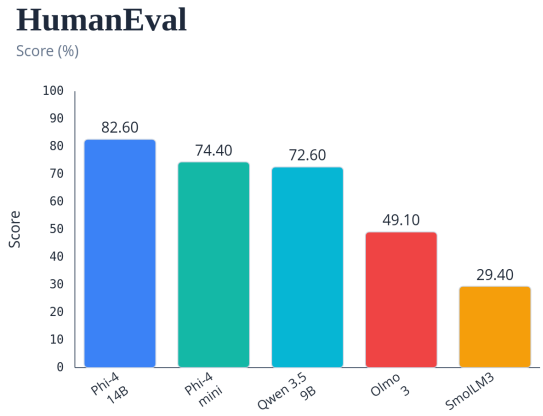

(d) Génération de code (HumanEval)

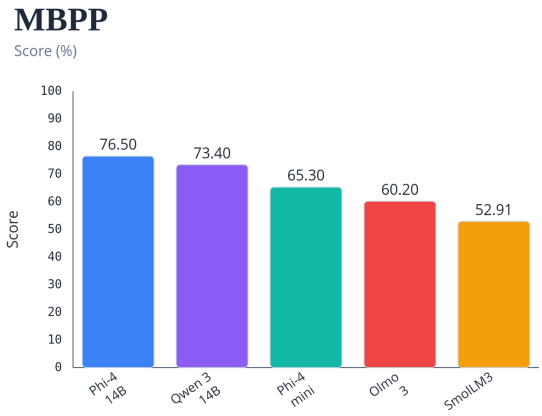

(e) Programmation de base (MBPP)

Figure 1: Visualisation comparative des performances des Small Language Models (SLM) par catégorie de benchmark.

L'analyse visuelle des graphiques révèle des dynamiques distinctes. Le Phi-4 14B domine le MMLU, tandis que Qwen 3 14B et Phi-4 mini excellent sur le GSM8K (Microsoft et al., 2025). Le MMLU-Pro marque une rupture avec la suprématie de Qwen 3.5 9B (Team, 2026), et Olmo 3 se distingue sur le BBH (Olmo et al., 2025).

5.4 Analyse et interprétation architecturale des performances

Les variations observées découlent de choix d'ingénierie différenciés. La famille Phi-4 exploite un corpus synthétique de haute qualité, justifiant sa régularité sur le code (Abdin et al., 2024; Microsoft et al., 2025). Le Qwen 3.5 9B illustre l'efficacité des architectures hybrides, intégrant des Gated DeltaNets et une structure Mixture-of-Experts (MoE) clairsemée (Team, 2026). Cette configuration optimise l'inférence tout en augmentant la capacité de raisonnement, soutenue par un apprentissage par renforcement (RL) à grande échelle (Yang et al., 2025).

Olmo 3 privilégie la transparence et l'optimisation des préférences via RLVR (Reinforcement Learning from Verifiable Rewards), expliquant sa force sur le BBH (Olmo et al., 2025). À l'inverse, SmolLM3 (3B) maximise l'utilité de ses paramètres via la Grouped Query Attention (GQA) et l'Anchored Preference Optimization (APO), permettant un mode "réflexion" performant malgré sa taille réduite (Bakouch et al., 2025).

5.5 Synthèse et détermination de l'état de l'art

L'état de l'art est désormais piloté par la spécialisation architecturale et le post-entraînement (RL et APO). Le modèle Phi-4 14B demeure l'architecture la plus polyvalente. Toutefois, sous le prisme de l'efficience, le Qwen 3.5 9B redéfinit le standard SOTA : il surclasse des modèles plus massifs sur le MMLU-Pro tout en optimisant les coûts d'inférence grâce à son architecture hybride (Team, 2026).

6 Limites de notre étude

L'analyse de l'état de l'art des Small Language Models (SLM) rencontre plusieurs limites liées à la méthodologie de sélection, à la nature des données disponibles dans la littérature ainsi qu'aux cadres d'évaluation actuels:

Opacité des conditions d'évaluation: Une limite majeure de cette étude réside dans le manque de données normalisées concernant les conditions d'évaluation des modèles. Bien que les articles rapportent des performances élevées, les protocoles expérimentaux (tels que la température, le format du prompt ou l'utilisation du zéro-shot par rapport au few-shot) varient considérablement d'une étude à l'autre, ce qui rend les comparaisons directes et les conclusions définitives difficiles à établir. De plus, de nombreuses évaluations proviennent des équipes de conception elles-mêmes, ce qui appelle à des validations par des tiers indépendants afin de garantir l'impartialité des scores.

Focalisation thématique et manque de diversité des domaines: Dans cet étude, on effectue une sélection des benchmarks en fonction de sa popularité et son acceptation. Or, ce choix nous fait négliger la variété des

benchmarks. Notre analyse met en évidence une forte concentration des benchmarks sur le raisonnement logique, les mathématiques et la génération de code. Il existe peu de données et de benchmarks standardisés dans notre corpus pour des domaines spécifiques tels que la médecine, le droit ou la finance, ce qui limite la portée de notre étude quant à l'efficacité des SLM dans ces secteurs spécialisés.
Choix opérationnel du seuil matériel: La définition d'un SLM comme un modèle de moins de 14 milliards de paramètres constitue un choix méthodologique propre à ce travail, visant à garantir son exécution sur des GPU grand public. Ce seuil correspond à une décision opérationnelle assumée et non à un standard établi dans la littérature. Par ailleurs, l'impact des techniques de quantification (par exemple GPTQ ou GGUF) sur la perte réelle de précision sur du matériel grand public reste une variable difficile à isoler en l'absence de tests physiques directs.
Limites des mesures de durabilité: Bien que nous intégrions le benchmark SLM-Bench, les indicateurs de consommation d'énergie et d'émissions de CO2 rapportés dans les articles reposent principalement sur des estimations fondées sur des formules standardisées (comme les outils Zeus ou MLCO2) plutôt que sur des mesures physiques directes effectuées à l'aide de capteurs sur les dispositifs. Cela limite la précision de notre analyse environnementale aux outils logiciels utilisés par les auteurs.
Risque de contamination et fiabilité des scores: L'analyse est également limitée par le risque de contamination des données (chevauchement entre les données d'entraînement et les ensembles de test tels que MMLU ou GSM8K), ce qui peut artificiellement gonfler les résultats rapportés dans les articles les plus récents. De plus, le recours fréquent à des juges automatiques (comme ChatGPT dans le cadre de ToolEval) introduit un biais de circularité dans l'évaluation des performances.
Évolutivité temporelle: Enfin, le domaine des SLM évolue à un rythme très rapide, et l'émergence constante de nouvelles architectures (par exemple des architectures hybrides ou des approches comme DeltaNets) est susceptible de rendre certaines conclusions de cette étude rapidement obsolètes.

7 Conclusion

Cet etat de l'art à mis en lumière les diverses capacités d'un modèle SLM, ainsi que les approches standardisées pour évaluer de manière systèmatique un SLM. Nous avons démontré qu'SLM ne constitue pas seulement une version compacte d'un LLM, mais qu'il va bien au-delà. Ses besoins en VRAM, sa consomation energetique et ses emissions de CO_2, sont moins significatives. Comme on à pu voir avec Yang et al. (2025) une optimisation supplémentaire peut être obtenue en utilisant des architectures intelligentes et des techniques avancées, permettant de diviser par dix le temps de distillation. En outre, les SLM permettent une exécution sur des dispositifs portables comme on a pu le voir avec le model présenté par Abdin et al. (2024). Cet ensemble de modèles et de méthodes d'évaluation permettront le développement futur des SLM. Nous espérons que cette étude contribuera positivement aux avancées dans ce domaine.

References

Abdin, M., Aneja, J., Awadalla, H., Awadallah, A., Awan, A. A., Bach, N., ... Zhou, X. (2024, April). *Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone.* arXiv. Retrieved 2026-02-01, from https://ui.adsabs.harvard.edu/abs/2024arXiv240414219A DOI: 10.48550/arXiv.2404.14219

Adamski, P., & Lubczonek, J. (2025, January). A Comparative Analysis of the Usability of Consumer Graphics Cards for Deep Learning in the Aspects of Inland Navigational Signs Detection for Vision Systems. *Applied Sciences*, *15*(9), 5142. Retrieved 2026-03-31, from https://www.mdpi.com/2076-3417/15/9/5142 DOI: 10.3390/app15095142

Bakouch, E., Ben Allal, L., Lozhkov, A., Tazi, N., Tunstall, L., Patiño, C. M., ... Wolf, T. (2025). *SmolLM3: smol, multilingual, long-context reasoner.* Retrieved from https://huggingface.co/blog/smollm3

Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., ... Zaremba, W. (2021, July). *Evaluating Large Language Models Trained on Code.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2107.03374 DOI: 10.48550/arXiv.2107.03374

Corradini, F., Leonesi, M., & Piangerelli, M. (2025, July). State of the Art and Future Directions of Small Language Models: A Systematic Review. *Big Data and Cognitive Computing*, *9*(7), 189. Retrieved 2026-02-17, from https://www.mdpi.com/2504-2289/9/7/189 DOI: 10.3390/bdcc9070189

Frantar, E., Ashkboos, S., Hoefler, T., & Alistarh, D. (2023, March). *GPTQ: Accurate Post-Training Quantization for Generative Pre-trained Transformers.* arXiv. Retrieved 2026-03-31, from http://arxiv.org/abs/2210.17323 (arXiv:2210.17323 [cs]) DOI: 10.48550/arXiv.2210.17323

Guan, X., Lyna Zhang, L., Liu, Y., Shang, N., Sun, Y., Zhu, Y., ... Yang, M. (2025, January). *rStar-Math: Small LLMs Can Master Math Reasoning with Self-Evolved Deep Thinking.* arXiv. Retrieved 2026-02-01, from https://ui.adsabs.harvard.edu/abs/2025arXiv250104519G DOI: 10.48550/arXiv.2501.04519

Koh, B., Walkinshaw, N., & Shin, D. (2026, January). *Detecting Multiple Semantic Concerns in Tangled Code Commits.* arXiv. Retrieved 2026-02-01, from http://arxiv.org/abs/2601.21298 DOI: 10.48550/arXiv.2601.21298

Li, M., Bi, Z., Wang, T., Wen, Y., Niu, Q., Song, X., ... Liu, M. (2025, November). *Deep Learning and Machine Learning with GPGPU and CUDA: Unlocking the Power of Parallel Computing.* arXiv. Retrieved 2026-03-31, from http://arxiv.org/abs/2410.05686 (arXiv:2410.05686 [cs]) DOI: 10.48550/arXiv.2410.05686

Lin, S., Hilton, J., & Evans, O. (2022, May). *TruthfulQA: Measuring How Models Mimic Human Falsehoods.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2109.07958 DOI: 10.48550/arXiv.2109.07958

Mahade Hasan, M., Waseem, M., Kemell, K.-K., Rasku, J., Ala-Rantala, J., & Abrahamsson, P. (2025, July). *Assessing Small Language Models for Code Generation: An Empirical Study with Benchmarks.* arXiv. Retrieved 2026-03-05, from https://ui.adsabs.harvard.edu/abs/2025arXiv250703160M DOI: 10.48550/arXiv.2507.03160

Microsoft, Abouelenin, A., Ashfaq, A., Atkinson, A., Awadalla, H., Bach, N., ... Zhou, X. (2025, March). *Phi-4-Mini Technical Report: Compact yet Powerful Multimodal Language Models via Mixture-of-LoRAs.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2503.01743 DOI: 10.48550/arXiv.2503.01743

Mitra, A., Corro, L. D., Mahajan, S., Codas, A., Simoes, C., Agarwal, S., ... Awadallah, A. (2023, November). *Orca 2: Teaching Small Language Models How to Reason.* arXiv. Retrieved 2026-01-30, from https://arxiv.org/abs/2311.11045 DOI: 10.48550/arXiv.2311.11045

Olmo, T., Ettinger, A., Bertsch, A., Kuehl, B., Graham, D., Heineman, D., ... Hajishirzi, H. (2025, December). *Olmo 3.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2512.13961 DOI: 10.48550/arXiv.2512.13961

Raina, R., Madhavan, A., & Ng, A. Y. (2009, June). Large-scale deep unsupervised learning using graphics processors. In *Proceedings of the 26th Annual International Conference on Machine Learning* (pp. 873–880). Montreal Quebec Canada: ACM. Retrieved 2026-03-31, from https://dl.acm.org/doi/10.1145/1553374.1553486 DOI: 10.1145/1553374.1553486

Suzgun, M., Scales, N., Schärli, N., Gehrmann, S., Tay, Y., Chung, H. W., ... Wei, J. (2022, October). *Challenging BIG-Bench Tasks and Whether Chain-of-Thought Can Solve Them.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2210.09261 DOI: 10.48550/arXiv.2210.09261

Team, Q. (2026, February). *Qwen3.5: Accelerating Productivity with Native Multimodal Agents.* Retrieved from https://qwen.ai/blog?id=qwen3.5

Thanh Pham, N., Kieu, T., Nguyen, D.-M., Xuan, S. H., Duong-Trung, N., & Le-Phuoc, D. (2025, August). *SLM-Bench: A Comprehensive Benchmark of Small Language Models on Environmental Impacts–Extended Version.* arXiv. Retrieved 2026-03-05, from https://ui.adsabs.harvard.edu/abs/2025arXiv250815478T DOI: 10.48550/arXiv.2508.15478

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., ... Azhar, F. (2023). Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*. Retrieved 2026-03-05, from https://formacion.actuarios.org/wp-content/uploads/2024/05/2302.13971-LLama-Open-and-Efficient-Foundation-Language-Models.pdf

Wang, Y., Ma, X., Zhang, G., Ni, Y., Chandra, A., Guo, S., ... Chen, W. (2024, November). *MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark.* arXiv. Retrieved 2026-03-30, from http://arxiv.org/abs/2406.01574 DOI: 10.48550/arXiv.2406.01574

Yang, A., Li, A., Yang, B., Zhang, B., Hui, B., Zheng, B., ... Qiu, Z. (2025, May). *Qwen3 Technical Report.* arXiv. Retrieved 2026-03-05, from http://arxiv.org/abs/2505.09388 DOI: 10.48550/arXiv.2505.09388

Declaration IA

Une aide minimale de l'IA à été employée dans ce manuscript afin de réaliser des corrections syntaxiques et gramaticales du texte.