État de l'art des Small Language Models inférieurs à 14 milliards de paramètres

Titouan Mokrani, Eliot Goarin, Noah Kalemba, Alfonso Jimenez, Hoang Dang

Universitée de Toulouse

Introduction

Les **Small Language Models (SLMs)** sont des modèles de langage de moins de 14 milliards de paramètres. Si les LLMs (GPT-4, Claude, Gemini) ont redéfini les capacités de l'IA générative, leur déploiement reste conditionné à des clusters GPU haute performance (A100, H100), hors de portée pour la majorité des développeurs.

Ce travail évalue la viabilité des SLMs comme alternative accessible, en soumettant **six modèles** à une batterie d'évaluations couvrant **six benchmarks**.

Qu'est-ce qu'un paramètre ? Pourquoi 14B ?

Un **paramètre** est un poids numérique appris pendant l'entraînement qui détermine le comportement du modèle. Plus un modèle en contient, plus il a de connaissances, **au prix d'un coût de calcul accrus**.

Le seuil de **14 milliards de paramètres** est une frontière pratique : un modèle 14B nécessite entre 7 et 24 Go de VRAM, le rendant exécutable sur un GPU grand public (RTX 3000/4000, 8–24 Go de VRAM). Au-delà, on entre dans la catégorie des LLMs nécessitant des infrastructures cloud dédiées.

Optimisation des SLMs

Il existe plusieurs stratégies pour compenser la taille réduite des SLMs et maximiser leur performance :

- **Données synthétiques :** Corpus de haute qualité de type *textbook* (Phi-4) pour compenser la taille réduite.
- **Quantization :** Réduction de la précision des poids (INT4, INT8) permettant l'exécution sur matériel grand public.
- **Distillation :** Un grand modèle (enseignant) transfère ses connaissances à un petit modèle (étudiant). Qwen démontre que cette approche nécessite **10 fois moins de calcul** que le Reinforcement Learning.

Les 6 Catégories de Benchmarks

L'évaluation couvre six dimensions cognitives et fonctionnelles :

1. **Compréhension du langage :** MMLU, connaissances et raisonnement.
2. **Mathématiques :** GSM8K, résolution de problèmes.
3. **Raisonnement complexe :** BBH, tâches multi-étapescomplexes.
4. **Génération de code :** HumanEval, MBPP, programmation algorithmique.
5. **Connaissances factuelles :** TriviaQA, mémorisation de faits.
6. **Sécurité et alignement :** TruthfulQA, ToxiGen, véracité, toxicité, critères HHH.

Modèles Évalués

- **Phi-4 14B** (Microsoft), SOTA polyvalent, données synthétiques
- **Phi-4 mini** (Microsoft), 3,8B, exécutable sur smartphone
- **Qwen 3 14B** (Alibaba), MoE, fort en raisonnement et code
- **Qwen 3.5 9B** (Alibaba), architecture hybride, RL à grande échelle
- **Olmo 3** (Allen AI), open-source, RLVR, transparent
- **SmolLM3 3B** (HuggingFace), ultra-compact, mode réflexion

Performances Comparées

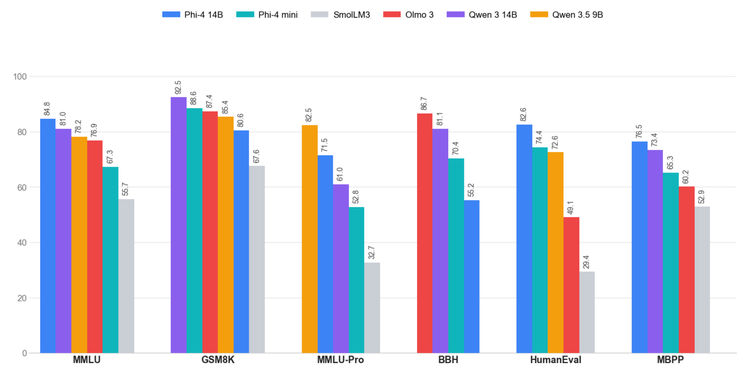

Figure 1. Scores détaillés par benchmark pour les principaux modèles $\leq$ 14B paramètres.

Résultats

Modèle	MMLU	GSM8K	MMLU-Pro	BBH	HumanEval	MBPP
Phi-4 14B	**84.8**	80.6	71.5	55.2	**82.6**	**76**
Phi-4 mini	67.3	88.6	52.8	70.4	74.4	65
SmolLM3 3B	55.7	67.6	32.7	—	29.4	52
Olmo 3	76.9	87.4	—	**86.7**	49.1	60
Qwen 3 14B	81.1	**92.5**	61.0	81.1	—	73
Qwen 3.5 9B	78.2	85.4	**82.5**	—	72.6	—

Phi-4 14B s'impose par sa régularité toutes tâches confondues. **Qwen 3.5 9B** surprend en dominant MMLU-Pro malgré ses 9B paramètres, surclassant des modèles plus massifs grâce à son architecture hybride.

Efficacité Paramétrique

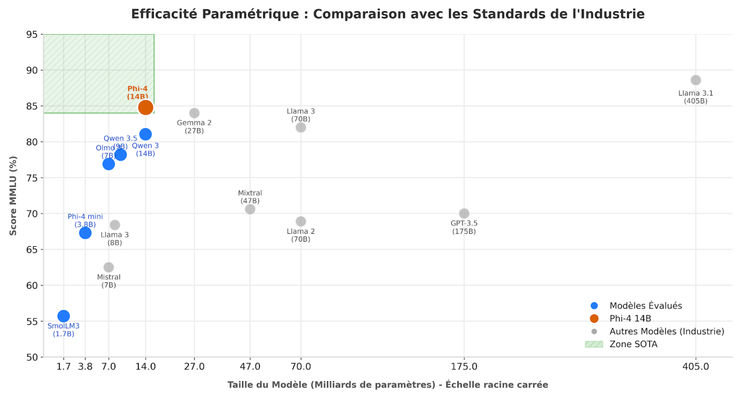

Figure 2. Efficacité Paramétrique : Comparaison avec les Standards de l'Industrie.

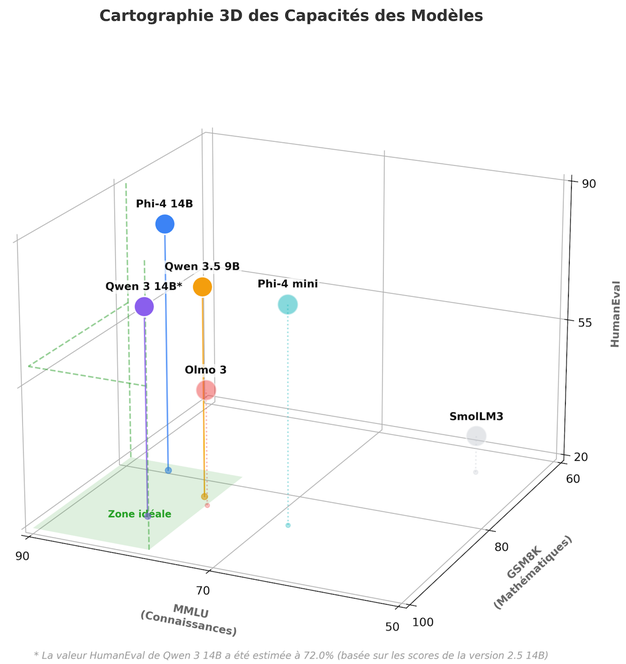

Figure 3. Représentation 3D des modèles SLM actuels.

Défis Restants

Malgré leurs succès, les SLMs font face à plusieurs limitations :

- **Connaissances factuelles limitées :** La taille réduite limite la mémorisation encyclopédique, pallié par RAG.
- **Hallucinations :** Tendance persistante à générer des informations incorrectes sur des requêtes complexes.
- **Opacité des évaluations :** Protocoles hétérogènes (température, few-shot vs zero-shot) et évaluations souvent réalisées par les concepteurs eux-mêmes.

IA Embarquée et Edge Computing

L'un des principaux atouts des SLMs est leur capacité à fonctionner **localement**, sur des appareils aux ressources limitées (smartphones, PC portables, IoT).

Atouts : Confidentialité, faible latence et fonctionnement hors-ligne sont garantis. Le RAG pallie le déficit de mémorisation. Empreinte carbone réduite de **60%** : $\sim$**417** vs $\sim$**1015 tCO_2eq** pour un LLM comparable. Llama-2-7B est le modèle le plus énergétiquement efficace parmi les SLMs étudiés

Conclusion

Les SLMs ne sont pas de simples versions réduites des LLMs : ce sont des modèles efficaces et hautement optimisés. Notre étude désigne **Phi-4 14B** comme référence polyvalente, tandis que **Qwen 3.5 9B** démontre qu'un modèle plus petit peut surpasser des modèles plus grands sur les tâches analytiques.

Références