État de l'art des Small Language Models inférieurs à 14 milliards de paramètres

Your Name

Universitée de Toulouse

Introduction

Les **Small Language Models (SLMs)**, définis ici comme des modèles de langage possédant moins de 14 milliards de paramètres, représentent une évolution majeure dans le domaine de l'IA générative. Contrairement à leurs homologues massifs (LLMs), ils offrent un compromis idéal entre **performances de haut niveau** et **faible coût computationnel**.

Ce poster synthétise l'état de l'art actuel de ces modèles, leurs capacités sur différents benchmarks, et leurs cas d'usage émergents.

Tendances Actuelles

L'écosystème des SLMs se concentre sur plusieurs axes d'optimisation :

- **Données d'entraînement :** Utilisation de corpus hautement qualitatifs (ex: Phi-3 entraîné sur des données textuelles de qualité *textbook*).
- **Quantization :** Réduction de la précision des poids (4-bit, 8-bit) pour permettre l'exécution sur du matériel grand public.
- **Spécialisation :** Création de modèles experts sur des tâches précises (code, mathématiques, résumé) plutôt que généralistes.

Modèles Phares

ieurs familles de modèles dominent actuellement cette catégorie :

1. **Qwen (Alibaba) :** Excellentes performances globales, avec des versions de 0.5B à 14B.
2. **Llama 3 (Meta) :** Le modèle 8B s'impose comme un standard de l'industrie pour sa polyvalence.
3. **Gemma (Google) :** Modèles de 2B et 7B basés sur la technologie Gemini, très performants en raisonnement.
4. **Phi-3 (Microsoft) :** Modèles de 3.8B et 7B optimisés pour le raisonnement logique et mathématique.

Performances Comparées

Le graphique ci-dessous illustre les scores détaillés obtenus par différents modèles sur un ensemble de benchmarks standards.

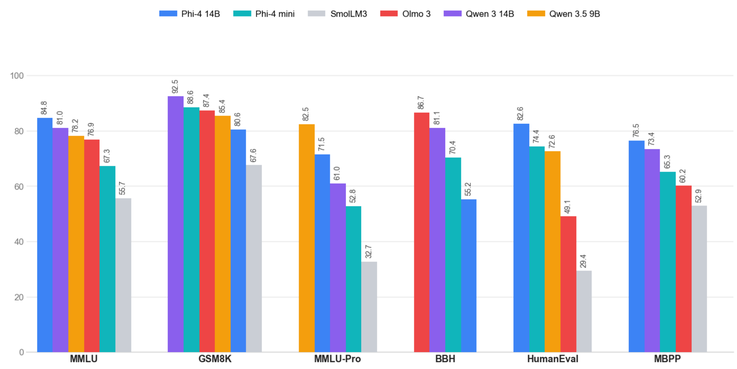

Figure 1. Scores détaillés par benchmark pour les principaux modèles $\leq$ 14B paramètres.

Défis Restants

Malgré leurs succès, les SLMs font face à plusieurs limitations :

- **Connaissances factuelles limitées :** La faible capacité de mémorisation réduit l'étendue de leurs connaissances encyclopédiques.
- **Hallucinations :** Tendance persistante à générer des informations incorrectes sur des requêtes complexes.
- **Raisonnement multi-sauts :** Difficultés à maintenir la cohérence sur des tâches nécessitant de nombreuses étapes de déduction.

Efficacité Paramétrique

Comparaison avec les standards de l'industrie montrant le compromis entre performances et taille du modèle :

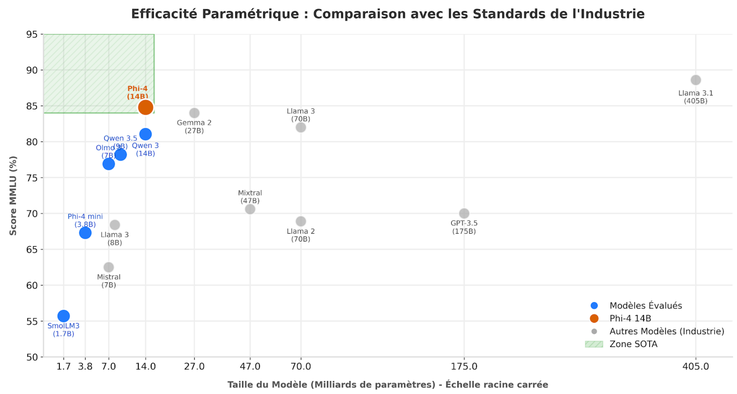

Figure 2. Efficacité Paramétrique : Comparaison avec les Standards de l'Industrie.

IA Embarquée et Edge Computing

L'un des principaux atouts des SLMs est leur capacité à fonctionner localement, sur des appareils aux ressources limitées (smartphones, PC portables, IoT).

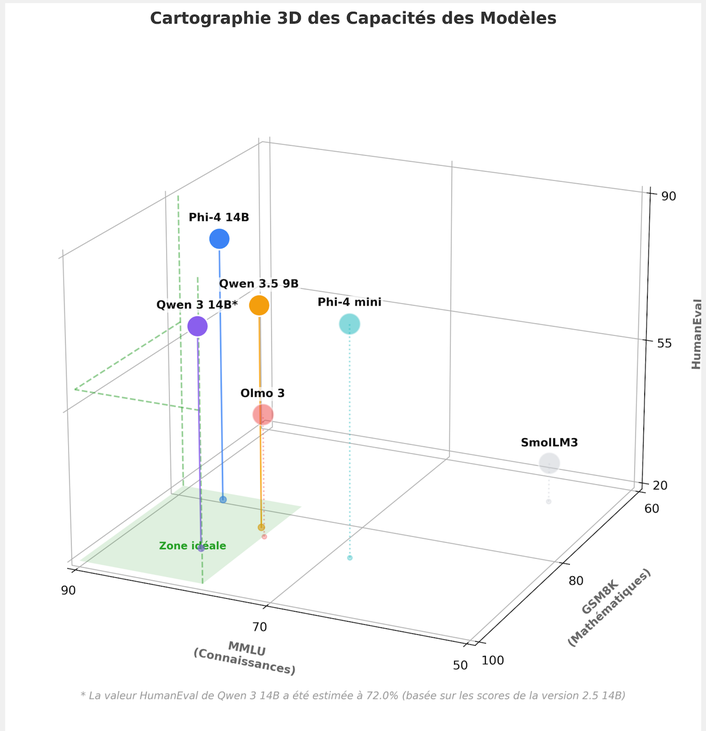

Figure 3. Représentation 3D des modèles SLM actuels.

L'exécution locale garantit la **confidentialité des données**, réduit la latence, et permet un fonctionnement hors-ligne (Edge AI). L'utilisation de *Retrieval-Augmented Generation (RAG)* permet de pallier leur manque de connaissances en les connectant à des bases de données locales sécurisées.

Conclusion

Les SLMs de moins de 14 milliards de paramètres ne sont plus de simples démonstrateurs technologiques. Ils s'imposent comme des **solutions viables, économiques et privées** pour l'intégration de l'IA générative en entreprise.

L'innovation se porte désormais sur l'amélioration des algorithmes d'entraînement et la distillation des connaissances depuis des LLMs plus massifs vers ces architectures compactes.

Références

[1] Claude E. Shannon.
A mathematical theory of communication.
Bell System Technical Journal, 27(3):379–423, 1948.