État de l'art des Small Language Models inférieurs à 14 milliards de paramètres

Titouan Mokrani, Eliot Goarin, Noah Kalemba, Alfonso Jimenez, Hoang Dang

Université de Toulouse

Avec l'aide de Thomas Trouve de chez Neusta France

Introduction

Les **Small Language Models (SLMs)** sont des modèles de langage dont le nombre de paramètres est inférieur à un certain seuil. Si les LLMs (GPT-4, Claude, Gemini) ont redéfini les capacités de l'IA générative, leur déploiement reste conditionné à des clusters GPU haute performance (A100, H100), hors de portée pour la majorité des développeurs [1].

Ce travail évalue la viabilité des SLMs comme alternative accessible, en soumettant **six modèles** à une batterie d'évaluations couvrant **quatre benchmarks**.

Un **paramètre** est un poids numérique appris à l'entraînement qui détermine le comportement du modèle. Nous fixons le seuil à **14 milliards de paramètres**, un choix *arbitraire* en l'absence de consensus dans la littérature. Ce choix correspond à la limite pratique d'exécution sur GPU grand public (RTX 3000/4000, 8–24 Go de VRAM).

Optimisation des SLMs

Il existe plusieurs stratégies pour compenser la taille réduite des SLMs et maximiser leur performance :

- **Quantization :** Réduction de la précision des poids (INT4, INT8) permettant l'exécution sur matériel grand public.
- **Données synthétiques :** Corpus de haute qualité de type *textbook* (Phi-4) pour compenser la taille réduite.
- **Distillation :** Un grand modèle (enseignant) transfère ses connaissances à un petit modèle (étudiant). Qwen démontre que cette approche nécessite **10 fois moins de calcul** que le Reinforcement Learning [3].

Les 4 Catégories de Benchmarks

L'évaluation couvre quatre dimensions cognitives et fonctionnelles :

1. **Compréhension du langage :** MMLU, connaissances et raisonnement.
2. **Mathématiques :** GSM8K, résolution de problèmes.
3. **Raisonnement complexe :** BBH, tâches multi-étapes complexes.
4. **Génération de code :** HumanEval, MBPP, programmation algorithmique.

Modèles Évalués

- **Phi-4 14B** (Microsoft), SOTA polyvalent, données synthétiques
- **Phi-4 mini** (Microsoft), 3.8B, exécutable sur smartphone
- **Qwen 3 14B** (Alibaba), MoE, fort en raisonnement et code
- **Qwen 3.5 9B** (Alibaba), architecture hybride, RL à grande échelle
- **Olmo 3** (Allen AI), open-source, RLVR, transparent
- **SmolLM3 3B** (HuggingFace), ultra-compact, mode réflexion

Performances Comparées

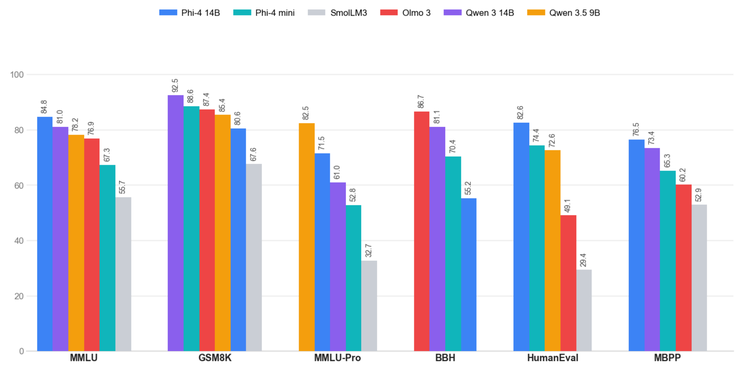

Figure 1. Scores détaillés par benchmark pour les principaux modèles $\leq$ 14B paramètres.

Résultats

Modèle	MMLU	GSM8K	MMLU-Pro	BBH	HumanEval	MBPP
Phi-4 14B	**84.8**	80.6	71.5	55.2	**82.6**	**76**
Phi-4 mini	67.3	88.6	52.8	70.4	74.4	65
SmolLM3 3B	55.7	67.6	32.7	—	29.4	52
Olmo 3	76.9	87.4	—	**86.7**	49.1	60
Qwen 3 14B	81.1	**92.5**	61.0	81.1	—	73
Qwen 3.5 9B	78.2	85.4	**82.5**	—	72.6	—

Phi-4 14B s'impose par sa régularité toutes tâches confondues. **Qwen 3.5 9B** surprend en dominant MMLU-Pro malgré ses 9B paramètres, surclassant des modèles plus massifs grâce à son architecture hybride.

Efficacité Paramétrique

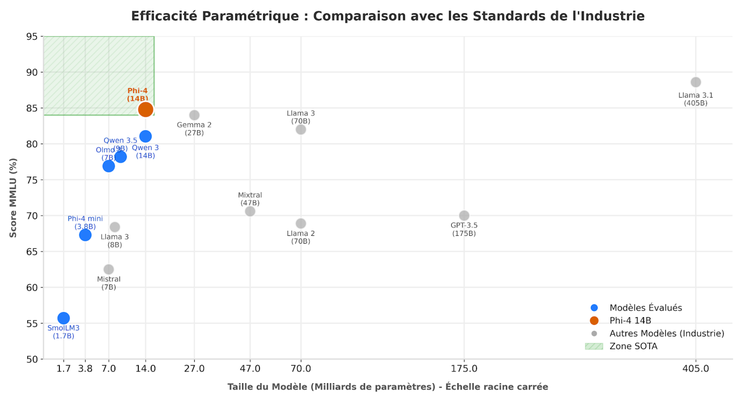

Figure 2. Efficacité paramétrique des SLMs étudiés comparés à des modèles plus massifs [1].

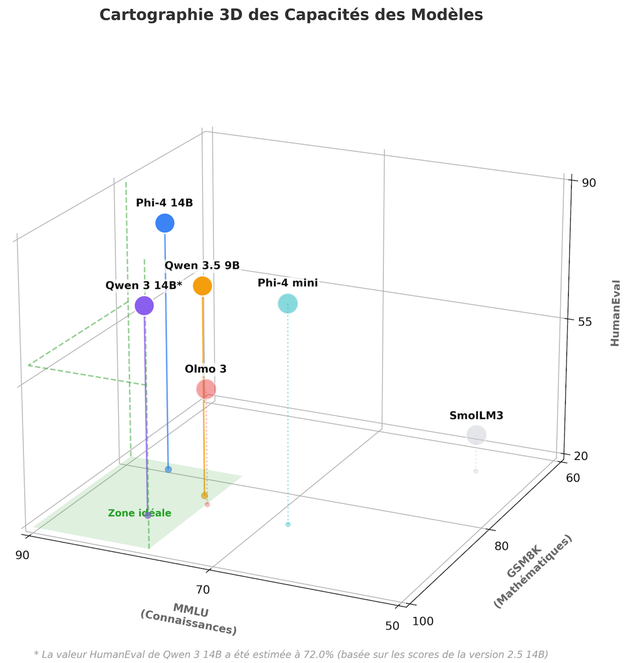

Figure 3. Représentation des performances des SLMs étudiés sur 3 benchmarks pertinents.

Défis Restants

Malgré leurs succès, les SLMs font face à plusieurs limitations :

- **Connaissances factuelles limitées :** La taille réduite limite la mémorisation encyclopédique, que le RAG permet de compenser.
- **Hallucinations :** Tendance persistante à générer des informations incorrectes sur des requêtes complexes.
- **Opacité des évaluations :** Protocoles hétérogènes (température, few-shot vs zero-shot) et évaluations souvent réalisées par les concepteurs eux-mêmes.

IA Embarquée et Edge Computing

L'un des principaux avantages des SLMs est leur capacité à fonctionner **localement**, sur des appareils aux ressources limitées (PC portables, IoT).

Atouts : Confidentialité, faible latence et fonctionnement hors-ligne sont garantis. Le RAG pallie le déficit de mémorisation. Empreinte carbone structurellement réduite par rapport aux LLMs, bien que les données précises restent limitées [2].

Conclusion

Les SLMs ne sont pas de simples versions réduites des LLMs : ce sont des modèles efficaces et hautement optimisés. Notre étude désigne **Phi-4 14B** comme référence polyvalente, tandis que **Qwen 3.5 9B** démontre qu'un modèle plus petit peut surpasser des modèles plus grands sur les tâches analytiques.

[1] Corradini et al. *State of the Art and Future Directions of SLMs.* BDCC, 2025. [2] Thanh Pham et al. *SLM-Bench: A Comprehensive Benchmark of SLMs on Environmental Impacts.* arXiv, 2025. [3] Yang et al. *Qwen3 Technical Report.* arXiv, 2025.