État de l'art des Small Language Models inférieurs à 14 milliards de paramètres

Your Name

Universitée de Toulouse

Introduction

Les **Small Language Models (SLMs)**, définis ici comme des modèles de langage possédant moins de 14 milliards de paramètres, représentent une évolution majeure dans le domaine de l'IA générative. Contrairement à leurs homologues massifs (LLMs), ils offrent un compromis idéal entre **performances de haut niveau** et **faible coût computationnel**.

Ce poster synthétise l'état de l'art actuel de ces modèles, leurs capacités sur différents benchmarks, et leurs cas d'usage émergents.

Tendances Actuelles

L'écosystème des SLMs se concentre sur plusieurs axes d'optimisation :

- **Données d'entraînement :** Utilisation de corpus hautement qualitatifs (ex: Phi-3 entraîné sur des données textuelles de qualité *textbook*).
- **Quantization :** Réduction de la précision des poids (4-bit, 8-bit) pour permettre l'exécution sur du matériel grand public.
- **Spécialisation :** Création de modèles experts sur des tâches précises (code, mathématiques, résumé) plutôt que généralistes.

Modèles Phares

ieurs familles de modèles dominent actuellement cette catégorie :

1. **Qwen (Alibaba) :** Excellentes performances globales, avec des versions de 0.5B à 14B.
2. **Llama 3 (Meta) :** Le modèle 8B s'impose comme un standard de l'industrie pour sa polyvalence.
3. **Gemma (Google) :** Modèles de 2B et 7B basés sur la technologie Gemini, très performants en raisonnement.
4. **Phi-3 (Microsoft) :** Modèles de 3.8B et 7B optimisés pour le raisonnement logique et mathématique.

Performances Comparées

Le graphique ci-dessous illustre les scores détaillés obtenus par différents modèles sur un ensemble de benchmarks standards.

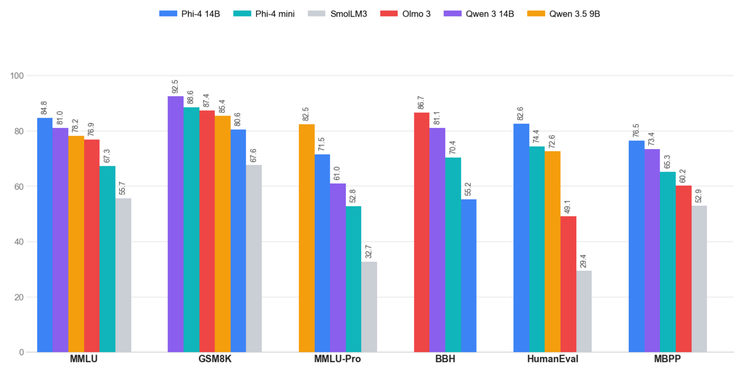

Figure 1. Scores détaillés par benchmark pour les principaux modèles $\leq$ 14B paramètres.

Défis Restants

Malgré leurs succès, les SLMs font face à plusieurs limitations :

- **Connaissances factuelles limitées :** La faible capacité de mémorisation réduit l'étendue de leurs connaissances encyclopédiques.
- **Hallucinations :** Tendance persistante à générer des informations incorrectes sur des requêtes complexes.
- **Raisonnement multi-sauts :** Difficultés à maintenir la cohérence sur des tâches nécessitant de nombreuses étapes de déduction.

Efficacité Paramétrique

Comparaison avec les standards de l'industrie montrant le compromis entre performances et taille du modèle :

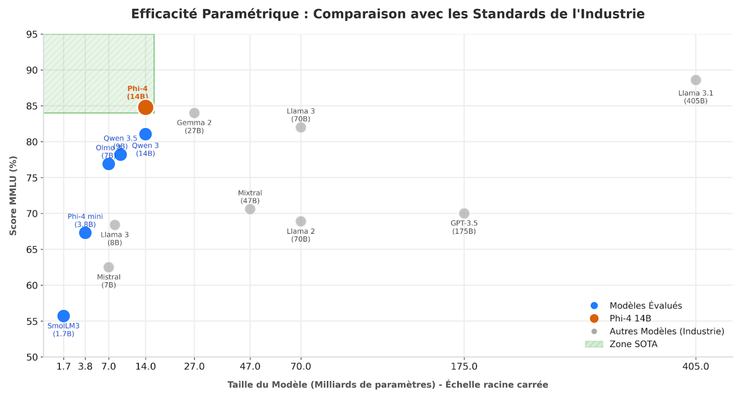

Figure 2. Efficacité Paramétrique : Comparaison avec les Standards de l'Industrie.

IA Embarquée et Edge Computing

L'un des principaux atouts des SLMs est leur capacité à fonctionner localement, sur des appareils aux ressources limitées (smartphones, PC portables, IoT).

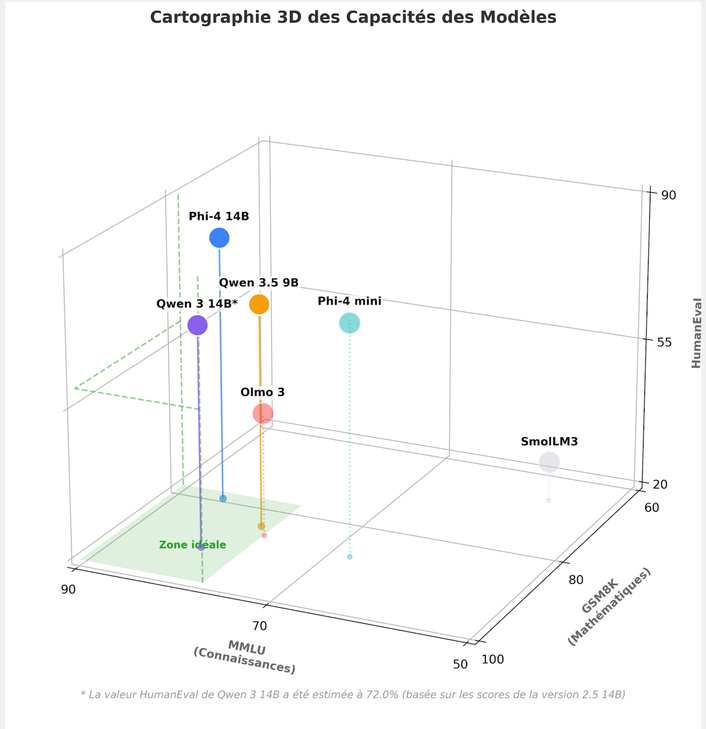

Figure 3. Représentation 3D des modèles SLM actuels.

L'exécution locale garantit la **confidentialité des données**, réduit la latence, et permet un fonctionnement hors-ligne (Edge AI). L'utilisation de *Retrieval-Augmented Generation (RAG)* permet de pallier leur manque de connaissances en les connectant à des bases de données locales sécurisées.

Conclusion

Cet état de l'art a démontré que les SLM ne sont pas de simples versions réduites des LLM, mais des modèles optimisés offrant une efficacité supérieure en VRAM et en consommation de CO_2. L'étude de [**?**] prouve notamment qu'une architecture intelligente peut diviser par dix le temps de distillation. Nos évaluations, conformes aux standards du domaine, désignent Phi-4 14B comme le SOTA actuel, bien que Qwen 3.5 9B surclasse ses concurrents sur MMLU-Pro. Ces résultats confirment la valeur ajoutée des SLM et ouvrent la voie à une IA plus accessible et durable.

Références